

Universidad de Jaén
Departamento de Informática

Tema 7

Otras tecnologías de BBDD distribuidas

Bases de Datos Distribuidas

Grado en Ingeniería Informática

CC BY NC ND

Profesor
Álvaro Labella Romero

Contenidos

- Tendencias actuales
- Blockchain



Tendencias actuales

Bases de Datos Distribuidas

Grado en Ingeniería Informática

CC BY NC ND

Introducción

- Las tendencias actuales en la gestión de datos distribuidos se centran en Internet
  - Gestionar petabytes de datos de forma:
    - Escalable: capacidad de crecer (en volumen o número de nodos) sin pérdida de rendimiento
    - Dinámica: adaptarse a los cambios en tiempo real, como la aparición de nuevos nodos
    - Fiable: mantener disponibilidad y consistencia incluso ante fallos
- Dos áreas importantes en esta dirección
  - Computación en la nube
  - Bases de datos peer-to-peer

La información de esta sección es original de Current Trends in Distributed Databases (brainkart.com)

Computación en la nube

- La computación en la nube es un paradigma que ofrece servicios a través de Internet en diferentes niveles de abstracción. Cuanto más subes el nivel:
  - Menos control tienes,
  - Menos cosas administras,
  - Más sencillo es usarlo
- Infraestructura (IaaS)
  - El proveedor ofrece infraestructura básica virtualizada: servidores, almacenamiento, red y capacidad de procesamiento
  - El usuario recibe una máquina virtual o similar y decide qué instalar encima (Linux, Windows, MongoDB, MySQL…)
  - Ejemplo: Amazon Web Services

Computación en la nube

- Plataformas (PaaS)
  - El proveedor ofrece un entorno completo de desarrollo y ejecución
  - El usuario no gestiona ni servidores ni sistema operativo, únicamente el código de la aplicación y los datos
  - Ejemplo: Google App Engine
    - Subes tu aplicación y la plataforma la ejecuta, escala automáticamente y gestiona recursos
- Software (SaaS)
  - El proveedor ofrece una aplicación determinada accesible por navegador o app
  - El usuario simplemente la utiliza, el proveedor lo gestiona todo
  - Ejemplo: Google Docs

COMPUTACIÓN EN LA NUBE

- Resumiendo...

Modelo	Usuario gestiona...	Proveedor gestiona...
IaaS	SO, BBDD, apps	Infraestructura
PaaS	Aplicación y datos	Infraestructura + Plataforma
SaaS	Solo uso funcional	Todo

Computación en la nube

- Nuevas arquitecturas distribuidas
  - Arquitecturas híbridas: parte de los datos y servicios están en servidores locales y parte en la nube.
  - Mantienes control sobre los datos críticos y aprovechas recursos cloud
  - Ejemplo: universidad con sistema híbrido
    - Servidores locales
      - Guarda los datos más sensibles o internos
      - Expedientes académicos, nóminas, datos personales…
    - Servicio en la nube
      - Servicios que necesitan escalabilidad o acceso remoto
      - Campus virtual, copias de seguridad, análisis de uso de la plataforma…
    - Un alumno entra al campus virtual, la autenticación se comprueba desde un sistema local, los apuntes y videos se sirven desde la nube, los logs de acceso se mandan a un servicio cloud

Computación en la nube

- Nuevas arquitecturas distribuidas
  - Multicloud: múltiples proveedores de nube
  - No hay infraestructura local, todo está en la nube, pero repartido en varios clouds
  - Ejemplo: tienda internacional online
    - Amazon Web Services: servidores web, base de datos de pedidos, procesamiento de pagos
    - Google: análisis de datos, recomendaciones de productos, herramientas de IA
    - Microsoft: copias de seguridad, autenticación
- Integración de datos estructurados y no estructurados
  - Datos estructurados -> tablas relacionales
  - Datos no estructurados -> imágenes, vídeos, documentos…
  - Hoy un sistema debe manejar ambos tipos de datos de forma conjunta.

Computación en la nube

- Procesamiento distribuido en tiempo real
  - Procesar datos nada más generarse (IoT, streaming…)
  - Baja latencia
  - Respuesta inmediata
  - No solo hay que almacenar datos, hay que reaccionar rápido
- Arquitecturas basadas en eventos
  - Un evento es algo que ocurre en el sistema (usuario inicia sesión, registro de un pago…)
  - Cada evento se almacena y otros servidores reaccionan
  - El dato no es lo único que importa, sino el hecho ocurrido.

Computación en la nube

- Problemas propios del mundo distribuido
  - Los fallos parciales son inevitables: algunos nodos siempre fallan
  - La sincronización global es costosa: mantener los nodos sincronizados consume recursos
  - Los problemas de las bases de datos distribuidas tradicionales se agravan en sistemas cloud
- Solución: partición y coordinación mínima
  - Dividir los datos en particiones -> cada nodo se ocupa de su fragmento de los datos
  - Las bases de datos distribuidas modernas se escalan más fácilmente porque minimizan la coordinación

COMPUTACIÓN EN LA NUBE

- Más problemas en los sistemas tradicionales
  - La partición dinámica no siempre se adapta bien al tipo de datos
  - Todos los datos se gestionan de forma similar
  - Limita la escalabilidad y desaprovecha recursos
- No todos los datos son iguales
  - Metadatos -> información de cómo está organizado el sistema
    - Necesitan más control y coherencia
  - Datos reales-> información que usa la aplicación
    - Pueden repartirse y gestionarse con más flexibilidad

Computación en la nube

- ¿Qué pasa cuando no hay distinción en la gestión de datos reales y los metadatos?
  - Todos los nodos deben de sincronizar ambos
  - Cambios frecuentes implica:
    - Más escritura coordinada
    - Más conflictos de accesos recurrentes
    - Más replicación
  - Sistema más lento y menos escalable

Computación en la nube

- En sistemas cloud distribuidos modernos:
  - Los metadatos de un sistema de base de datos distribuida se desacoplan de sus datos reales para garantizar la escalabilidad
  - La idea es separar claramente su gestión, almacenándolos y tratándolos con mecanismos distintos
    - Dado que los metadatos son solo una fracción del conjunto total de datos, se puede usar una BD tradicional (por ejemplo, centralizada)
- Las bases de datos distribuidas en la nube suelen diseñarse para operaciones simples sobre objetos individuales (sube esta imagen, añade este pedido, lee este documento…), lo que evita transacciones costosas y ganan en escalabilidad y eficiencia

Computación en la nube

- Evolución actual de las aplicaciones en la nube
  - Cada vez más aplicaciones trasladan sus datos y servicios a infraestructuras cloud
  - Inicialmente, la nube se utilizó sobre todo para:
    - Almacenamiento
    - Análisis masivo de datos
    - Procesamiento distribuido
  - Actualmente, también migra la lógica de negocio
    - Gestión de pedidos
    - Facturación
    - Gestión de usuarios
  - El desafío clave es mantener la coherencia funcional del sistema sin perder escalabilidad
    - La lógica empresarial suele implicar relaciones entre datos: clientes, pedidos, pagos…
    - Estas relaciones exigen: consistencia, coordinación entre nodos, buen rendimiento distribuido
    - Cuanta más lógica compleja entra en la nube, más difícil es equilibrar consistencia y escalabilidad.

Computación en la nube

- Cuando compras en Amazon:
  - se descuenta stock,
  - se registra pedido,
  - se genera pago,
  - se actualiza envío
- Todo ocurre en sistemas distribuidos y hay que garantizar la coherencia funcional entre los diferentes procesos
- Cuanta más coherencia, es necesaria más coordinación entre los nodos
- Reto real: **muchas operaciones relacionadas sobre nodos distintos**

BBDD P2P

- Un sistema de base de datos peer-to-peer (PDBS) tiene como objetivo integrar las ventajas del modelo P2P (peer-to-peer) con las características de la gestión de datos descentralizada
- “Peer” significa igual
- Todos los nodos tienen un rol equivalente
- No existe un servidor central que controle a los demás
- BitTorrent
  - Cuando alguien descarga un archivo en BitTorrent no lo obtiene de un único servidor central, lo recibe de múltiples nodos al mismo tiempo
  - Cada nodo es cliente y servidor:
    - Tiene una parte del archivo
    - Comparte esa parte
    - Recibe otras partes

BBDD P2P

- En un PDBS cada nodo puede:
  - almacenar datos,
  - procesar consultas,
  - responder a otros nodos,
  - colaborar en la distribución
- Para encontrar o consultar algo, el sistema propaga consultas
  - Analogía -> comunidad de vecinos donde:
    - Cada uno tiene su propia biblioteca (datos)
    - Si quieres un libro, puedes preguntarles directamente a los vecinos que conoces
    - Algunos vecinos te redirigen a otros si no lo tienen
    - No hay una biblioteca central… pero todos colaboran

BBDD P2P

- En PDBS
  - No existe un esquema global único
  - Cada nodo mantiene su propio esquema de datos
  - Cada nodo decide cómo organiza su información
  - Consecuencia -> dos nodos pueden representar el mismo concepto de forma distinta: Nodo A (CLIENTES), Nodo B (USUARIOS)
- Cómo se resuelven las consultas
  - El usuario consulta un nodo local
  - El nodo interpreta qué otros nodos pueden aportar información necesaria
  - La consulta se adapta al esquema local de cada nodo y se reenvía
- Ruta semántica
  - El sistema busca equivalencias entre esquemas -> CLIENTES.nombre = USUARIOS.nomb
  - Cada nodo procesa lo que conoce, envía la parte restante a otros peers vecinos y combina resultados



Blockchain

Bases de Datos Distribuidas

Grado en Ingeniería Informática

CC BY NC ND

INTRODUCCIÓN

La información de esta sección es original de [Blockchain Tutorial: Learn Blockchain Technology (Examples) (guru99.com)]

- **Blockchain** se puede definir como una cadena de bloques enlazados que contiene información distribuida en diferentes nodos y que no puede ser modificada
  - Cada bloque contiene
    - Datos
    - Sello de tiempo (timestamp)
    - Hash del bloque anterior, formando una cadena
  - Cualquier cambio en un bloque, rompería la cadena -> es inmutable
  - No hay un servidor central, todos los nodos tienen una copia y verifican los nuevos bloques
- Se utiliza para la transferencia segura de elementos como dinero, propiedad, contratos, etc., sin necesidad de un intermediario externo como un banco o un gobierno
  - Una vez que los datos se registran dentro de una cadena de bloques, es muy difícil cambiarlos
  - Puede considerarse como una BBDD distribuida con limitaciones (solo se puede añadir bloques, rendimiento bajo…)

Videos de blockchain:
https://www.youtube.com/watch?v=V9Kr2SujqHw&t=713s
https://www.youtube.com/watch?v=ApKUtfjpxFo&ab_channel=DotCSV

Introducción

- **Ejemplo:** Tener un sistema **seguro y confiable** donde cada paciente tenga su historial médico completo, accesible **desde cualquier centro de salud**, y sin posibilidad de ser manipulado o perdido
- Cada vez que se hace una visita al médico se genera un registro y se añade un nuevo bloque a la "cadena médica" del paciente
- Ventajas
  - Inmutabilidad -> nadie puede alterar el historial médico
  - Distribución -> cada centro médico tiene una copia del historial médico
  - Transparencia con privacidad -> el paciente autoriza a que partes se pueden acceder

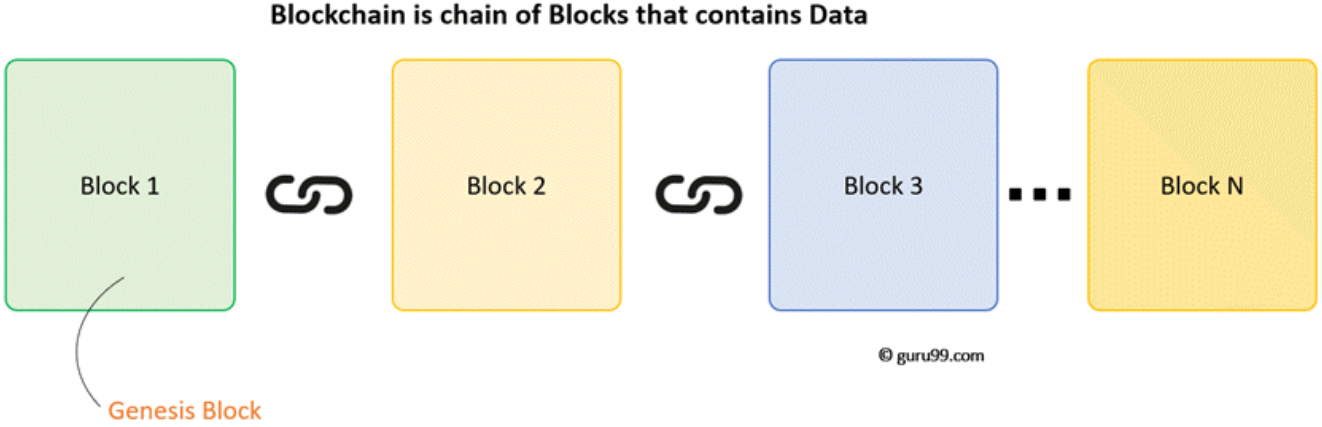
Introducción

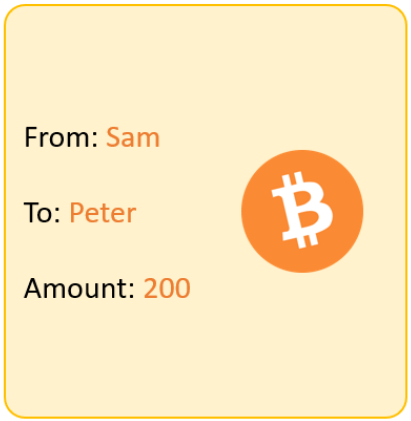
- La cadena de bloques es un protocolo de software (como SMTP lo es para correo electrónico)
  - También se le llama meta-tecnología porque afecta a otras tecnologías
  - Se compone de: una base de datos, una aplicación de software, una red de ordenadores, etc.
- A veces, el término se usa para Bitcoin Blockchain, Ethereum Blockchain, etc.
  - Fue el primer uso que se le dio a Blockchain
  - Sin embargo, la mayoría de ellos están hablando de libros de contabilidad (ledgers) distribuidos
  - Un ledger es un registro cronológico de transacciones



ARQUITECTURA

- Un **Blockchain** es una cadena de bloques que contienen información. Los datos que se almacenan dentro de un bloque dependen del tipo de blockchain
  - Por ejemplo, un bloque de Bitcoin contiene información sobre el remitente, el receptor y la cantidad de bitcoins que se transferirán

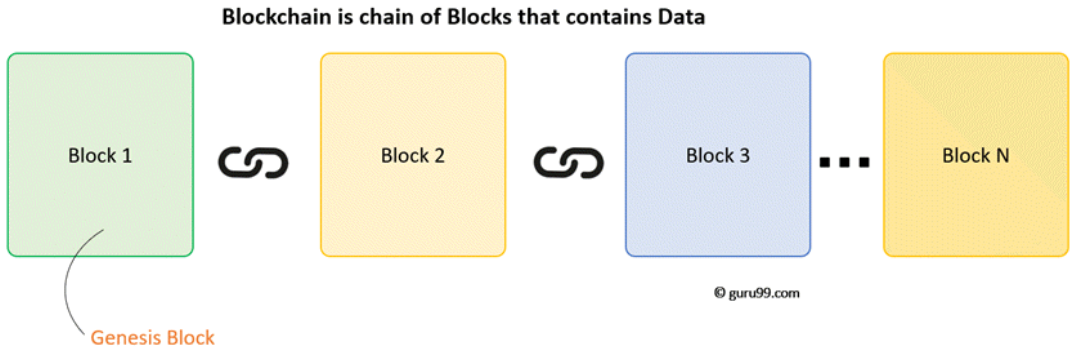




Bitcoin Block Example

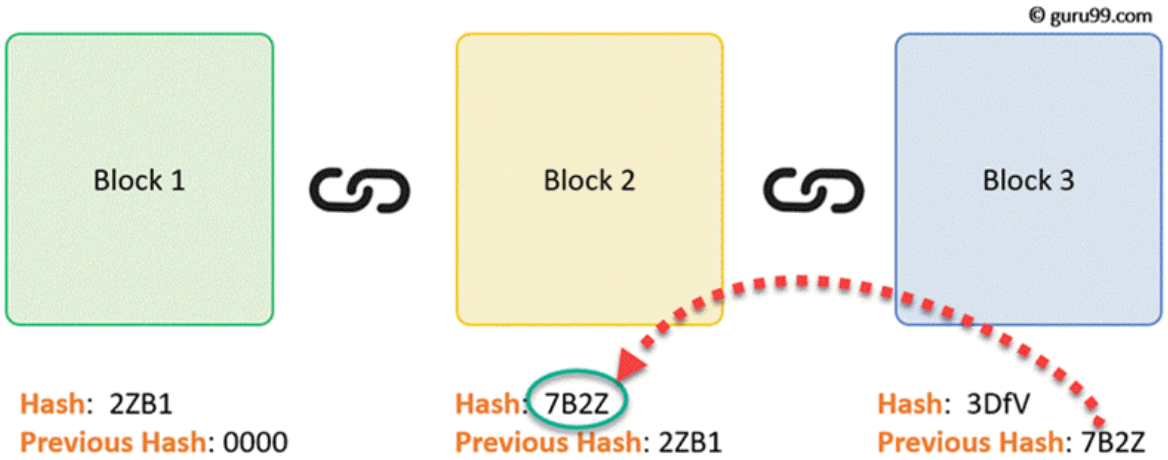
ARQUITECTURA

- El primer bloque de la cadena se llama bloque **Génesis**. Cada nuevo bloque de la cadena está vinculado al bloque anterior
- Un bloque también tiene un hash
  - Puede entenderse como una huella dactilar que es única para cada bloque
  - Identifica un bloque y todo su contenido, y siempre es único
  - Una vez que se crea un bloque cualquier cambio hará que su hash cambie también
  - Se utiliza SHA256



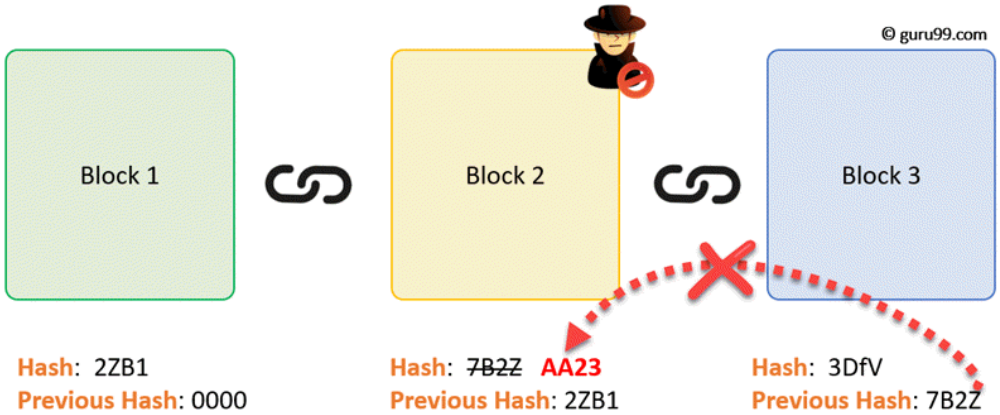
ARQUITECTURA

- El hash es muy útil cuando se quiere detectar cambios en las transacciones
  - Si la huella dactilar de un bloque cambia, no permanece el mismo bloque
- Cada bloque tiene
  1. Datos
  2. Hash
  3. Hash del bloque anterior



ARQUITECTURA

- Ejemplo de seguridad
  - Un atacante puede cambiar los datos presentes en el Bloque 2, por lo que su hash cambia
  - Pero el bloque 3 todavía contiene el antiguo hash del bloque 2
    - Esto hace que el bloque 3 y todos los bloques siguientes sean inválidos, ya que no tienen el hash correcto del bloque anterior
  - Por lo tanto, cambiar un solo bloque puede invalidar rápidamente todos los bloques siguientes

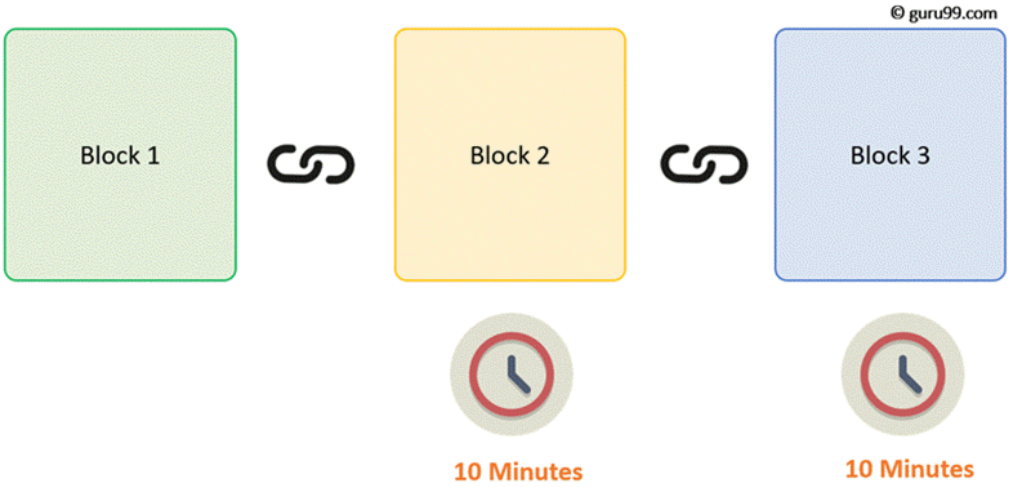


ARQUITECTURA

- Prueba de trabajo (Proof of Work)
  - Los hashes son un mecanismo excelente para evitar la manipulación
    - Pero las computadoras actuales pueden calcular cientos de miles de hashes por segundo
    - En cuestión de unos minutos un atacante puede manipular un bloque y luego volver a calcular todos los valores hash de otros bloques para que la cadena de bloques vuelva a ser válida
  - Para evitar esto, las cadenas de bloques utilizan el concepto de prueba de trabajo (PoW)
    - Es un mecanismo que ralentiza la creación de nuevos bloques, haciéndola costosa computacionalmente
  - Un **PoW** es un problema computacional que requiere cierto esfuerzo para resolverlo
    - Pero el tiempo necesario para verificar los resultados del problema computacional es muy inferior en comparación con el esfuerzo que se necesita para resolver el problema computacional en sí
    - Ejemplo: “Encuentra un número que, combinado con el hash del bloque actual, dé como resultado un hash que comience con 10 ceros”. -> Problema sin atajos (fuerza bruta) que requiere un gran consumo de recursos

ARQUITECTURA

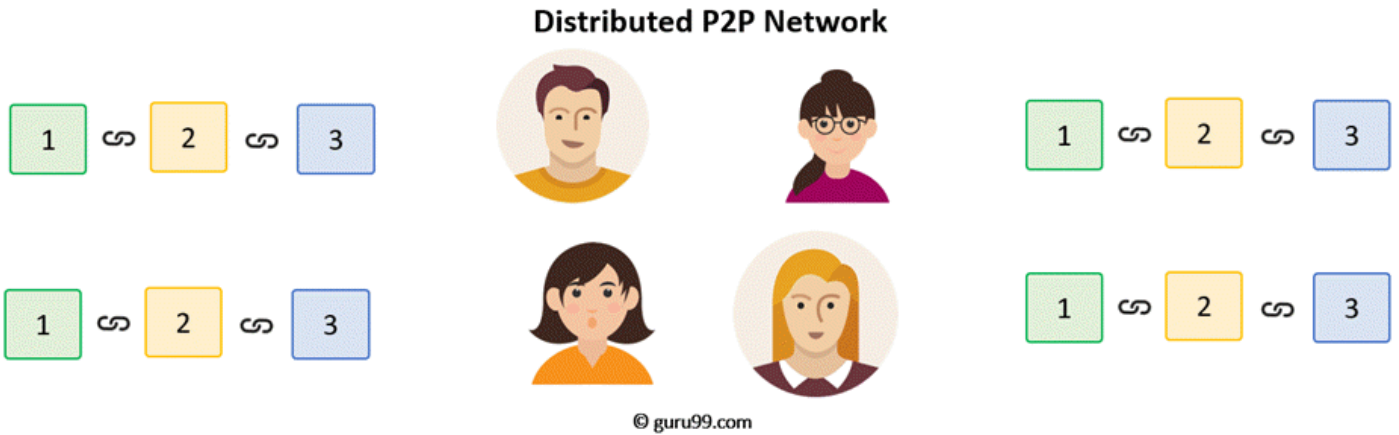
- Prueba de trabajo (Proof of Work)
  - En el caso de Bitcoin se necesitan casi 10 minutos para calcular la prueba de trabajo requerida para agregar un nuevo bloque a la cadena
  - Este tipo de mecanismo hace que sea bastante difícil manipular los bloques
    - Incluso si se manipula un solo bloque, se deberá volver a calcular el PoW de todos los bloques siguientes
    - El atacante tendría que **rehacer el PoW de ese bloque *y* de todos los siguientes**, en menos tiempo que el resto de la red sigue añadiendo bloques válidos.



ARQUITECTURA

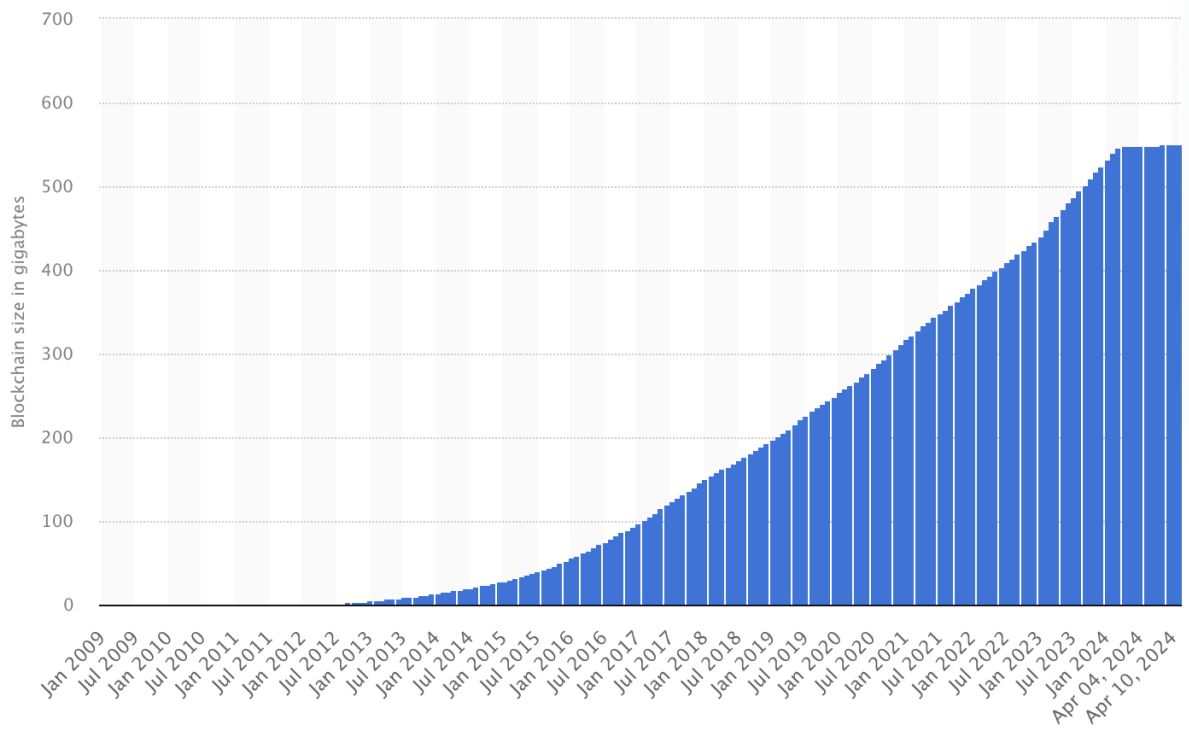
Red distribuida P2P

- En lugar de usar una entidad central para administrar la cadena, Blockchain usa una red distribuida entre pares, y todos pueden unirse
- Cuando alguien ingrese a esta red, obtendrá la copia completa de la cadena de bloques
  - Cada computadora se llama nodo



Size of the Bitcoin blockchain from January 2009 to April 11, 2024

(in gigabytes)



© Statista 2024

Additional Information

Show source

DOWN

Sourc

Sho

Sho

Use

Releas

April 2(

Regio

Worldv

Surve

January

Suppl

The nu

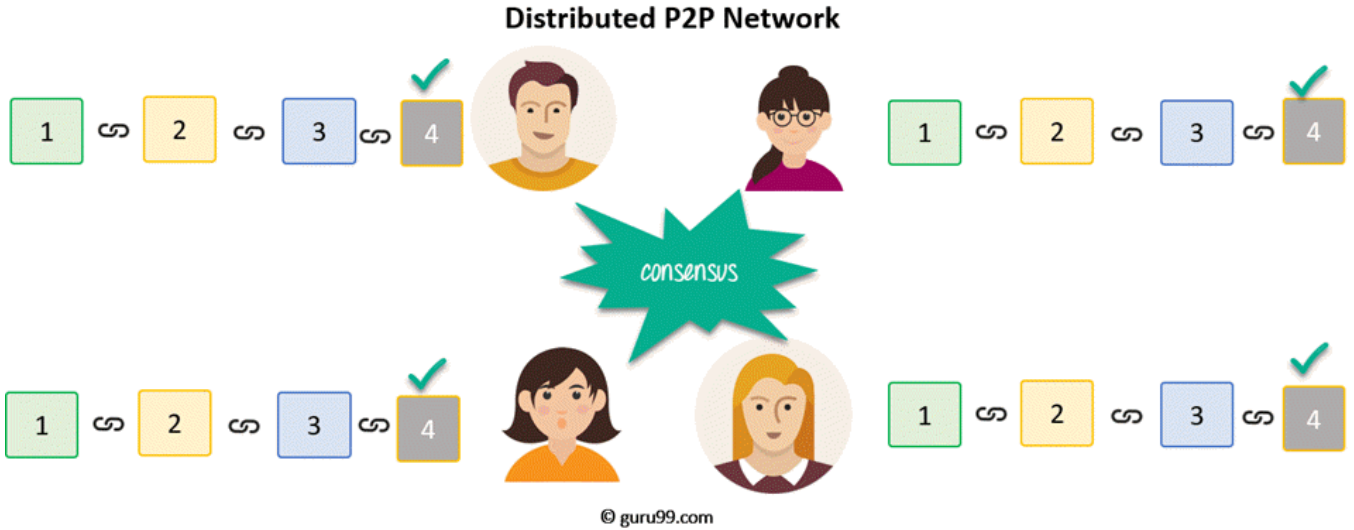
megab

1GB ec

Citati

ARQUITECTURA

- Cuando un usuario crea un nuevo bloque se envía a todos los usuarios de la red
- Cada nodo verifica el bloque (PoW) para asegurarse de que no haya sido alterado
- Después de la verificación completa, cada nodo agrega este bloque a su cadena de bloques

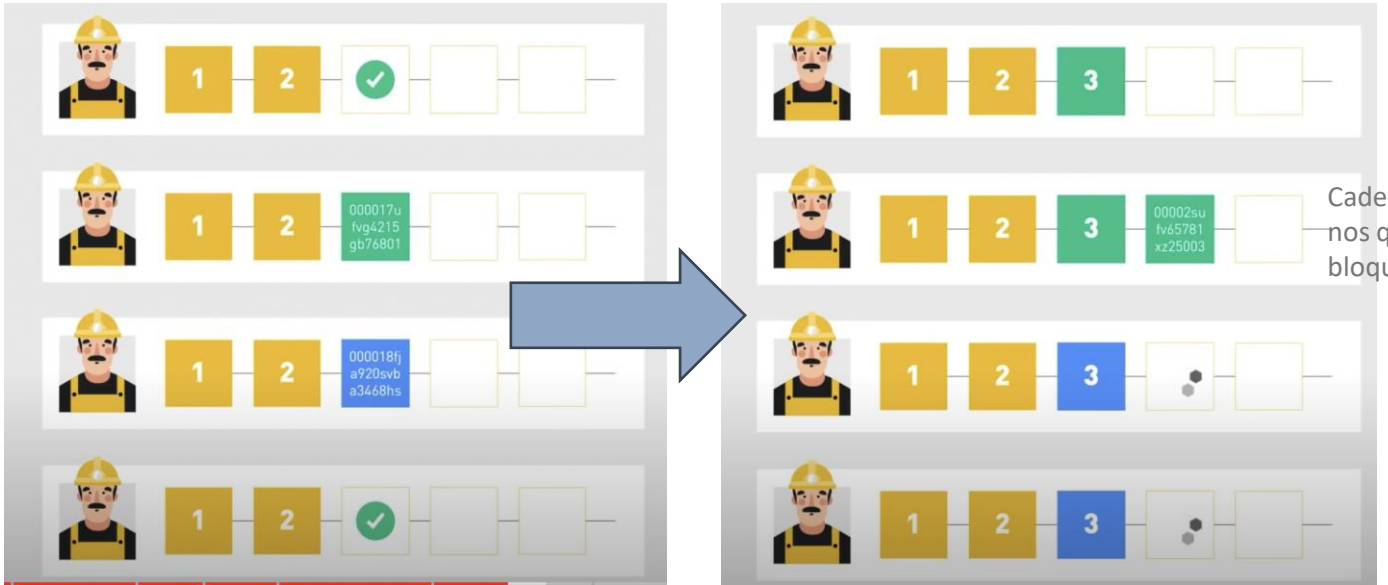


ARQUITECTURA

- Si dos nodos generan un nuevo bloque validado a la vez, se mantienen ambos, hasta que llegue el siguiente. Y se mantiene el de la cadena más larga.
- El otro bloque se descarta, y no obtiene recompensa.

Genera un bloque

Genera un bloque



Cadena más larga, nos quedamos con el bloque verde

Se descarta

Se descarta

Arquitectura

- Todos los nodos de esta red crean un consenso
  - Están de acuerdo sobre qué bloques son válidos y cuáles no
  - Los nodos de la red rechazarán los bloques manipulados
- Para manipular con éxito una cadena de bloques
  1. Hay que manipular todos los bloques de la cadena
  2. Rehacer la PoW para cada bloque
  3. Tomar el control de más del 50% de la red P2P
- Esta manipulación es una tarea casi imposible
  - Por eso las Blockchains son tan seguras

TRANSACCIONES

- Funcionamiento de las **transacciones**
  - Paso 1) Alguna persona solicita una transacción. La transacción podría involucrar criptomonedas, contratos, registros u otra información
  - Paso 2) La transacción solicitada se transmite a una red P2P con la ayuda de otros nodos
  - Paso 3) La red de nodos valida la transacción y el estado del usuario con la ayuda de algoritmos
  - Paso 4) Una vez que se completa la transacción, el nuevo bloque se agrega a la cadena de bloques existente, de tal manera que sea permanente e inalterable



Fortalezas del Blockchain

- Resistencia y seguridad: Blockchain es una arquitectura replicada
  - La cadena todavía funciona en caso de un ataque masivo contra el sistema
- Reducción de tiempo: en la industria financiera, blockchain puede desempeñar un papel vital al permitir la liquidación más rápida de las operaciones eliminando intermediarios
  - No necesita un largo proceso de verificación, establecimiento y liquidación porque se incluye una única versión de los datos acordados en la bitácora compartida, disponible para todos los interesados
- Fiabilidad: Blockchain certifica y verifica las identidades de los interesados
- Transacciones inmutables: al registrar las transacciones en orden cronológico, Blockchain certifica la inalterabilidad de todas las operaciones
  - Cuando se agrega un bloque a la bitácora, no se puede eliminar ni modificar

Fortalezas del Blockchain

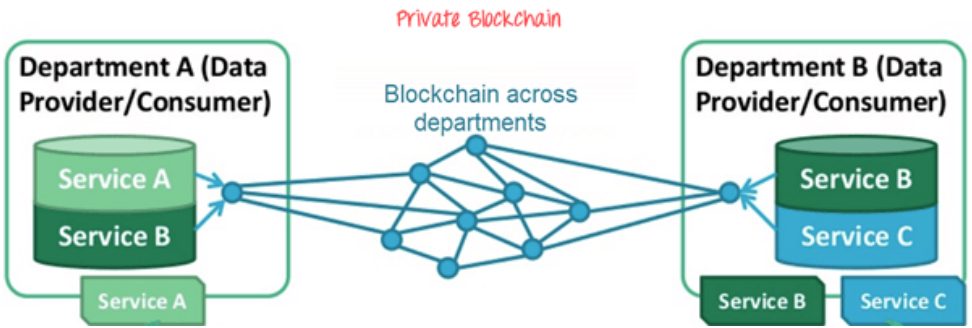
- Prevención del fraude: los conceptos de información compartida y consenso previenen posibles pérdidas por fraude o malversación
  - En las industrias logísticas, blockchain como mecanismo de monitoreo actúa para reducir costos, de manera que se puede registrar cada paso del envío del producto
- Transparencia: los cambios en las cadenas de bloques **públicas** son visibles para todos
  - Esto ofrece una mayor transparencia y todas las transacciones son inmutables
- Colaboración: permite a las partes realizar transacciones directamente entre sí sin la necesidad de mediar con terceros
- Descentralizado: existen reglas estándares sobre cómo cada nodo intercambia la información de la cadena de bloques
  - Este método asegura que todas las transacciones estén validadas y que se agreguen una a una

VERSIONES

- Blockchain 1.0: Moneda
  - Implementación de DLT (tecnología de contabilidad distribuida) para criptomonedas
  - Esto permite transacciones financieras basadas en tecnología blockchain
  - Se utiliza en moneda y pagos. Bitcoin es el ejemplo más destacado en este segmento
- Blockchain 2.0: contratos inteligentes
  - Smart Contracts, pequeños programas informáticos que "viven" en la cadena de bloques
  - Son programas informáticos gratuitos que se ejecutan automáticamente y verifican las condiciones definidas anteriormente como facilitación, verificación o ejecución
  - Se utiliza como sustituto de los contratos tradicionales
  - Ejemplo: Si alguien envía 2 bitcoins a la dirección del contrato, a ese alguien se le enviará un fichero PDF con un libro digital
- Blockchain 3.0: Dapps (aplicaciones descentralizadas):
  - Tiene su código de backend ejecutándose en una red P2P descentralizada -> contratos inteligentes
  - Una DApp puede tener un código de ejemplo de blockchain frontend e interfaces de usuario escritas en cualquier idioma que pueda realizar una llamada a su backend, como una aplicación tradicional

VARIANTES

- Pública:
  - Los libros de contabilidad son visibles para todos en Internet
  - Permite que cualquiera verifique y agregue un bloque de transacciones a la cadena de bloques
  - Las redes públicas tienen incentivos para que las personas se unan y sean de uso gratuito
  - Cualquiera puede usar una red pública de blockchain
- Privado:
  - La cadena de bloques privada está dentro de una sola organización
  - Permite que solo personas específicas de la organización verifiquen y agreguen bloques de transacciones



Variantes

- Consorcio
  - En esta variante de Blockchain, solo un grupo de organizaciones puede verificar y agregar transacciones
  - Aquí, la bitácora puede estar abierta o restringida a grupos seleccionados
  - La cadena de bloques del consorcio se utiliza entre organizaciones
  - Solo está controlado por nodos preautorizados

USOS Y APLICACIONES

Ver el video de Dapps
https://www.youtube.com/watch?v=RCv_ArHI81I

- Mercados
  - Facturación, seguimiento y transferencia de datos
  - Gestión de cuotas en la Supply Chain Network
- Sector gubernamental
  - Servicios de gobernanza personalizada transnacional
  - Votación, proposiciones P2P bond
  - Digitalización de documentos / contratos y comprobante de titularidad para transferencias
  - Registro e identificación
  - Servicio de tele-abogado
  - Registro e intercambio de IP
  - Recibos de impuestos Servicio notarial y registro de documentos
- IOT
  - Redes de sensores agrícolas
  - Redes de drones
  - Redes domésticas inteligentes
  - Smartcity integrado
  - Sensores domésticos inteligentes
  - Coche autónomo
  - Robots personalizados, componente robótico
  - Drones personalizados
  - Asistentes digitales
- Ciencia y arte
  - Supercomputación
  - Análisis de multitudes
  - Recursos P2P
  - Servicios digitales Mind Fit
- Salud
  - Gestión de datos
  - Bancos de datos de EMR Health
  - QS Data Commons
  - Analitos de flujo de datos de gran salud
  - Billetera de salud digital Propiedad inteligente
  - Token de salud
  - Contratos de desarrollo personal
- Contabilidad financiera
  - Pago en moneda digital
  - Pagos y remesas
  - Mercados de capital en Blockchain
  - Contabilidad entre divisiones
  - Compensación, negociación y derivados
  - Teneduría de libros

Inconvenientes de Blockchain

- Costos más altos: los nodos buscan recompensas más altas por completar transacciones en una empresa que funciona según el principio de oferta y demanda. Si hay muchas transacciones, los usuarios tienen que pagar más para obtener prioridad
- Transacciones más lentas: los nodos priorizan las transacciones con recompensas más altas, y se acumulan atrasos en las transacciones
- Bitácora menor: cuando no es posible obtener una copia completa de Blockchain (tamaño excesivo), lo que potencialmente puede afectar la inmutabilidad, el consenso, etc.
- Costos de transacción, velocidad de la red: el costo de transacción de Bitcoin es bastante alto después de haber sido promocionado como "casi gratuito" durante los primeros años

Inconvenientes de Blockchain

- Riesgo de error: Siempre existe el riesgo de error, cuando interviene el factor humano
  - En caso de que una cadena de bloques sirva como base de datos, todos los datos entrantes deben ser de alta calidad
  - Contratos o transacciones mal redactados
  - Blockchain no comete errores, pero tampoco los corrige
- Derroche de tiempo: cada nodo que ejecuta la cadena de bloques debe mantener el consenso en toda la cadena de bloques
  - Esto ofrece un tiempo de inactividad muy bajo y hace que los datos almacenados en la cadena de bloques sean inalterables para siempre
  - Sin embargo, todo esto es un desperdicio, todos los nodos verifican y almacenan lo mismo y se gasta mucha energía

Comparativa con BBDD distribuidas

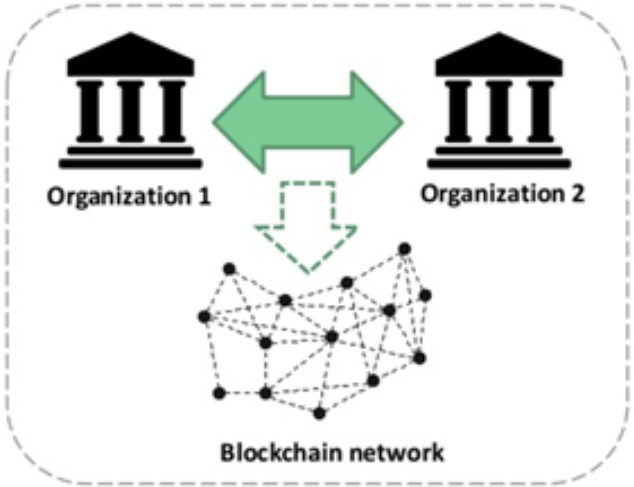
Parameters	Blockchain	Shared Database
Operations	Insert	Create/ Read/ Update and Delete
Replication	Full replication on every peer	Primary-secondary Multi-primary
Consensus	Most of the peers agree on the outcome of transactions	Distributed transactions which held in two phases commit
Validation	Global rules enforced on the whole blockchain system	Offers only local integrity constraints
Disintermediation	It is allowed with blockchain	Not allowed (always an admin or central system control)
Confidentiality	Fully confidential	Not totally confidential (depend on configuration)
Robustness	Fully robust technology	Not entirely robust (dependency of coordinator node)

COMPARATIVA CON BBDD DISTRIBUIDAS



Superuser

Autoridad central que coordina y garantiza seguridad, integridad, acceso, validación



Crowdsourced

Intercambio de información sin intermediarios, la validación se hace de forma distribuida, no hay autoridad central