Importante
Puedo eliminar la publi de este documento con 1 coin
¿Cómo consigo coins? → Plan Turbo: barato
→ Planes pro: más coins

Inteligencia Artificial · Ingeniería Informática · UJA

Tema 8: Ética en la Inteligencia Artificial

Resumen completo para examen · Basado en las diapositivas

Índice

1. Introducción: Miedos y retos de la IA **2**
1.1. ¿Qué se necesita de la IA? . . . 2
1.2. Enfoque proactivo vs. reactivo . . . 2

2. Directrices Éticas para una IA Fiable **2**
2.1. Marco de la Comisión Europea . . . 2
2.2. Tres componentes de la fiabilidad . . . 3
2.3. Los 4 Principios Éticos Fundamentales . . . 3
2.3.1. 1. Respeto de la autonomía humana . . . 3
2.3.2. 2. Prevención del daño . . . 3
2.3.3. 3. Equidad . . . 4
2.3.4. 4. Explicabilidad . . . 4
2.4. Los 7 Requisitos Clave de la IA Fiable . . . 5
2.5. IA Fiable a lo Largo del Ciclo de Vida Software . . . 5

3. Propuesta Europea de Reglamento sobre la IA **5**
3.1. Planteamiento Basado en el Riesgo . . . 6

4. Oficina Europea de Inteligencia Artificial **7**

5. Ley de Inteligencia Artificial **8**
5.1. Objetivos de la Ley . . . 8
5.2. Relación con los marcos anteriores . . . 8

6. Resumen Final — Todo de un Vistazo **9**
6.1. Ideas Clave del Tema . . . 9
6.2. Comparativa: Principios vs. Requisitos . . . 9
6.3. Puntos Clave para el Examen . . . 10

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

1. Introducción: Miedos y retos de la IA

La IA ya está transformando aspectos cotidianos —salud, seguridad, productividad, educación y ocio— de forma a menudo invisible para el usuario final. Pese a ello, los sistemas actuales siguen siendo **IA especializada**: resuelven tareas concretas pero no poseen inteligencia general comparable a la humana.

Premisa fundamental

Las IAs futuras, por muy capaces que sean, serán **distintas** a la inteligencia humana: sus cuerpos, sus datos y su entorno de diseño condicionan su comportamiento. Por ello, su **alineación con valores humanos** no es automática y debe diseñarse explícitamente.

1.1. ¿Qué se necesita de la IA?

Los sistemas de IA se enfrentan simultáneamente a cuatro tipos de cuestiones:

- **Técnicas**: robustez, precisión, resistencia a ataques.
- **Legales**: cumplimiento de normativas vigentes.
- **Éticas**: respeto a valores y derechos fundamentales.
- **Regulatorias**: sujeción a marcos de supervisión institucional.

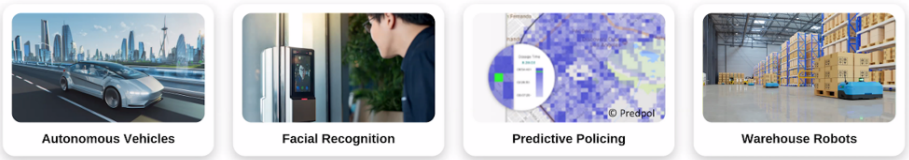


Figura 1: Ejemplos de aplicaciones de IA que plantean retos técnicos, éticos y regulatorios: vehículos autónomos, reconocimiento facial, policía predictiva y robots de almacén. (Fuente: Diapositiva 6 del temario)

1.2. Enfoque proactivo vs. reactivo

Enfoque *ex-post* (reactivo): actuar una vez que los daños ya han ocurrido. Este enfoque **no es el adecuado**.
Enfoque proactivo: definir de antemano qué queremos de la IA y diseñarla en consecuencia. Es nuestra responsabilidad como diseñadores.

El objetivo final es lograr una **IA fiable, confiable y ética**, resumida en la pregunta: *¿podemos construir sistemas autónomos que no fallen en entornos extremos y que respeten los derechos de las personas?*

2. Directrices Éticas para una IA Fiable

2.1. Marco de la Comisión Europea

La Comisión Europea, a través de sus comunicaciones de 2018, definió una visión de IA ética y segura *«made in Europe»*, apoyada en tres pilares:

1. Aumentar inversiones públicas y privadas en IA.

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

WUOLAH
Las descargas sin publicidad se realizan con las coins

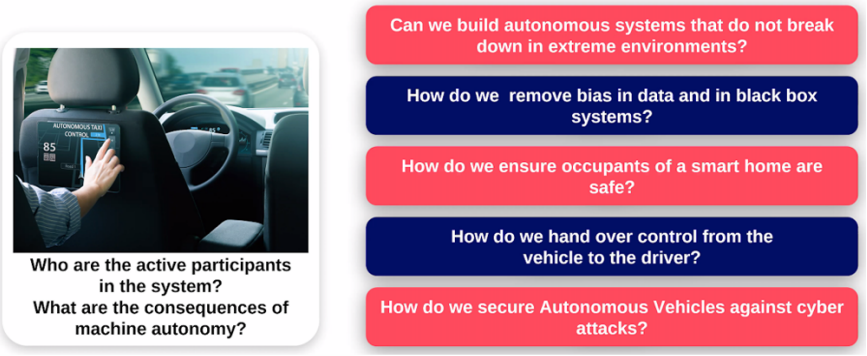


Figura 2: Preguntas clave que definen el desafío de una IA fiable y confiable en aplicaciones reales. (Fuente: Diapositiva 8 del temario)

2. Prepararse para los cambios socioeconómicos derivados.
3. Garantizar un marco **ético y legal** acorde con los valores europeos.

   Para ello encargó al *Grupo de Expertos de Alto Nivel* la elaboración de:

- Directrices éticas sobre IA.
- Recomendaciones sobre política e inversión.

2.2. Tres componentes de la fiabilidad

IA Fiable

La fiabilidad de un sistema de IA requiere satisfacer **simultáneamente** tres condiciones a lo largo de todo su ciclo de vida:

1. **IA lícita**: cumple toda la legislación aplicable.
2. **IA ética**: respeta principios y valores éticos.
3. **IA robusta**: sólida técnica y socialmente; minimiza daños accidentales incluso con buenas intenciones.

2.3. Los 4 Principios Éticos Fundamentales

2.3.1. 1. Respeto de la autonomía humana

Los sistemas de IA deben **aumentar, completar y potenciar** las capacidades humanas, nunca subordinarlas o manipularlas. Esto implica:

- No coaccionar ni condicionar injustificadamente el comportamiento de las personas.
- Diseñar mecanismos de **supervisión y control humano** sobre los sistemas de IA.
- Garantizar que los usuarios puedan participar en el proceso democrático con plena autonomía.

2.3.2. 2. Prevención del daño

Los sistemas de IA no deben perjudicar a los seres humanos. Implica atender a:

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

WUOLAH

Las descargas sin publicidad se realizan con las coins

Importante
Puedo eliminar la publi de este documento con 1 coin
¿Cómo consigo coins? → Plan Turbo: barato
→ Planes pro: más coins

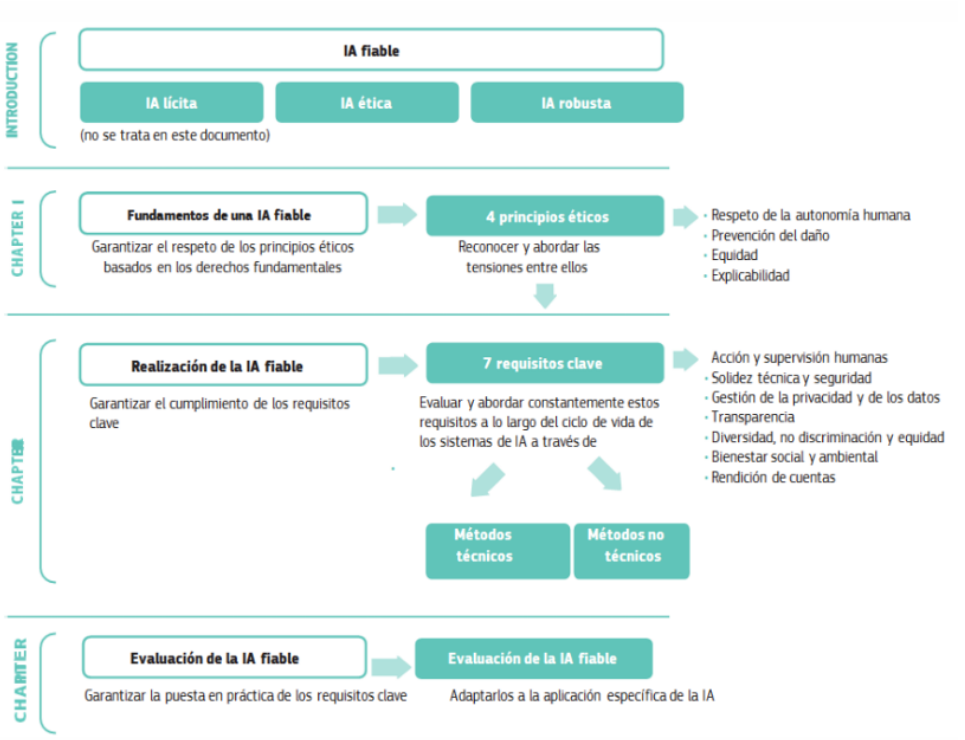


Figura 3: Marco completo para una IA fiable: principios éticos, requisitos clave y métodos de evaluación a lo largo del ciclo de vida del sistema. (Fuente: Diapositiva 14 del temario)

- **Seguridad** y **robustez** del sistema.
- Protección especial de **personas vulnerables** para evitar asimetrías de poder o información.

2.3.3. 3. Equidad

El desarrollo, despliegue y uso de la IA debe ser equitativo:

- Ausencia de **sesgos injustos** (p. ej. sesgos en los datos de entrenamiento).
- Proporcionalidad entre medios y fines.
- La equidad está ligada a la explicabilidad: para impugnar una decisión automática hay que poder entender cómo se generó.

2.3.4. 4. Explicabilidad

Crucial para que los usuarios **confíen** en la IA. Abarca:

- **Transparencia** en los procesos de decisión.
- **Trazabilidad y auditabilidad**, especialmente en sistemas de caja negra (*black box*).
- El grado de explicabilidad requerido depende del contexto y tipo de sistema.

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

★ Para el examen — Los 4 principios

Autonomía	Los humanos conservan el control y la toma de decisiones.
No daño	La IA no puede perjudicar a las personas.
Equidad	Sin sesgos injustos; proporcionalidad.
Explicabilidad	Transparencia y trazabilidad de las decisiones.

2.4. Los 7 Requisitos Clave de la IA Fiable

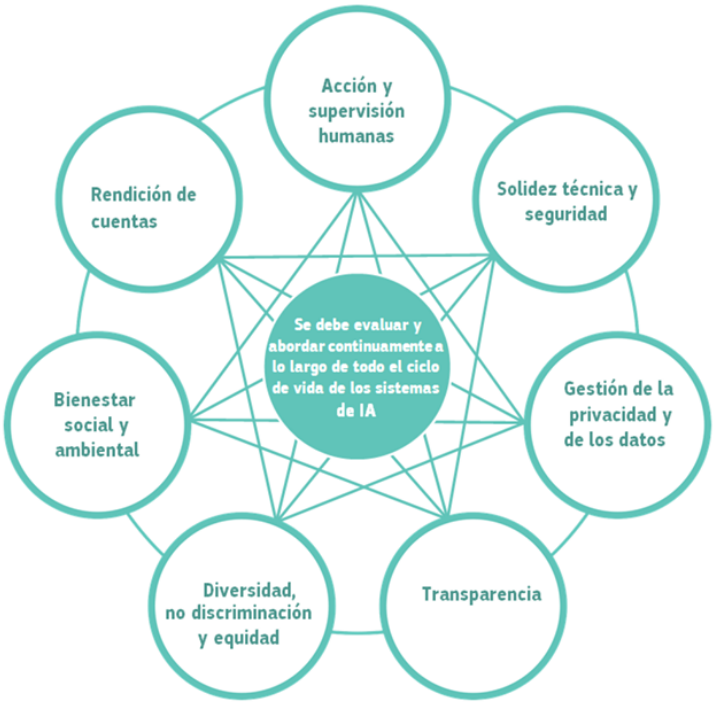


Figura 4: Los 7 requisitos clave de una IA fiable, interconectados y a evaluar continuamente a lo largo del ciclo de vida del sistema. (Fuente: Diapositiva 18 del temario)

2.5. IA Fiable a lo Largo del Ciclo de Vida Software

Los requisitos no se evalúan una sola vez: deben aplicarse en **todas las fases** del desarrollo.

Ejemplo práctico — Evaluación de privacidad y datos:

- ¿Se han analizado los tipos de datos usados (personales, sensibles)?
- ¿Se ha minimizado el uso de datos personales?
- ¿Existen mecanismos de consentimiento y revocación?
- ¿Se aplican técnicas de cifrado, anonimización o agregación?

3. Propuesta Europea de Reglamento sobre la IA

En **abril de 2021**, la Comisión Europea propuso un nuevo Reglamento con el objetivo de convertir a Europa en el centro mundial de una **IA confiable y centrada en las personas**. Sus características principales:

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

WUOLAH

Las descargas sin publicidad se realizan con las coins

Requisito	Descripción
1. Acción y supervisión humanas	Salvaguarda de derechos fundamentales y control humano efectivo sobre los sistemas de IA.
2. Solidez técnica y seguridad	Resistencia a ataques, plan de repliegue, fiabilidad y reproducibilidad de resultados.
3. Gestión de privacidad y datos	Respeto a la privacidad, calidad e integridad de los datos y control de acceso.
4. Transparencia	Trazabilidad, explicabilidad y comunicación clara hacia el usuario.
5. Diversidad, no discriminación y equidad	Ausencia de sesgos injustos, accesibilidad y diseño universal.
6. Bienestar social y ambiental	Sostenibilidad, impacto social positivo y respeto al medio ambiente y la democracia.
7. Rendición de cuentas	Auditabilidad, minimización de efectos negativos y búsqueda de compensaciones adecuadas.

Cuadro 1: Los 7 requisitos clave para la realización de una IA fiable según las Directrices de la Comisión Europea.

- Normas **proporcionadas y flexibles** adaptadas al nivel de riesgo de cada sistema.
- Aplicación **directa y uniforme** en todos los Estados miembros.
- Definición de IA *«a prueba de futuro»*.

3.1. Planteamiento Basado en el Riesgo

El reglamento clasifica los sistemas de IA en cuatro niveles de riesgo.

★ Para el examen — Alto riesgo: obligaciones

Un sistema de IA de alto riesgo debe garantizar:

- Evaluación y mitigación de riesgos adecuada.
- Conjuntos de datos de alta calidad (minimizar resultados discriminatorios).
- Registro de actividad (trazabilidad de resultados).
- Documentación completa para evaluación de conformidad.
- Información clara y adecuada al usuario.
- Supervisión humana apropiada.
- Alto nivel de solidez, seguridad y precisión.

4. Oficina Europea de Inteligencia Artificial

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

WUOLAH

Las descargas sin publicidad se realizan con las coins

Importante
Puedo eliminar la publi de este documento con 1 coin
¿Cómo consigo coins? → Plan Turbo: barato
→ Planes pro: más coins

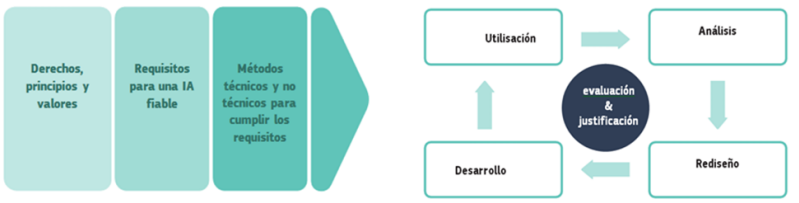


Figura 5: La IA fiable debe integrarse en el ciclo completo: análisis, rediseño, desarrollo y utilización, con evaluación y justificación continua en cada iteración. (Fuente: Diapositiva 19 del temario)

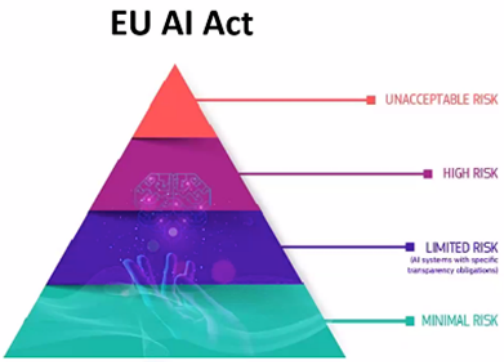


Figura 6: Pirámide de riesgo del EU AI Act: cuatro niveles desde riesgo mínimo hasta riesgo inaceptable. (Fuente: Diapositiva 22 del temario)

Creación

La Comisión Europea aprueba el **24 de enero de 2024** la creación de la **Oficina Europea de Inteligencia Artificial**.

Sus funciones principales:

- Supervisar los avances en **modelos de IA de uso general** (*General Purpose AI / GPAI*).
- Coordinar la interacción con la comunidad científica (investigaciones y pruebas).
- Ejecutar las normas del reglamento a escala europea.
- Actuar conforme a los procesos internos de la Comisión, sin menoscabar las competencias de las autoridades nacionales.

Cada Estado miembro deberá establecer su propia **Agencia Nacional de Inteligencia Artificial**, que trabajará en coordinación con la Oficina Europea.

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

Nivel de riesgo	Descripción y ejemplos
Inaceptable	**Prohibición total.** Sistemas que manipulan el comportamiento humano de forma subliminal, o que permiten «puntuación social» (*social scoring*) gubernamental.
Alto	**Obligaciones estrictas** antes de comercializarse: evaluación y mitigación de riesgos, alta calidad de datos, registro de actividad (trazabilidad), documentación detallada, información clara al usuario y supervisión humana. Incluye: infraestructuras críticas, formación, empleo, servicios esenciales, aplicación de la ley, justicia. *Todos los sistemas de identificación biométrica se incluyen aquí.*
Limitado	**Obligaciones de transparencia.** El usuario debe saber que interactúa con una máquina (p. ej., chatbots).
Mínimo o nulo	**Sin restricciones.** La gran mayoría de sistemas de IA: videojuegos, filtros de spam, etc.

Cuadro 2: Clasificación de sistemas de IA según el nivel de riesgo en el EU AI Act.

5. Ley de Inteligencia Artificial

Aprobación

La Comisión Europea aprueba el **13 de marzo de 2024** la **Ley de Inteligencia Artificial** (*AI Act*), elevando a rango de ley el reglamento propuesto en 2021.

5.1. Objetivos de la Ley

- Proteger los **derechos fundamentales**, la democracia, el Estado de derecho y la sostenibilidad medioambiental frente a la IA de alto riesgo.
- Impulsar la **innovación** posicionando a Europa como líder del sector.
- Establecer obligaciones para la IA en función de sus **riesgos potenciales** y su **nivel de impacto**.

5.2. Relación con los marcos anteriores

Hito	Descripción
2018	Comunicaciones de la Comisión; visión IA ética *made in Europe*.
2019	Directrices éticas del Grupo de Expertos de Alto Nivel; 4 principios y 7 requisitos.
Abril 2021	Propuesta de Reglamento con planteamiento basado en riesgo.
Enero 2024	Creación de la Oficina Europea de IA.
Marzo 2024	**Ley de Inteligencia Artificial** (AI Act) aprobada.

Cuadro 3: Cronología de la regulación europea de la IA.

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

WUOLAH

Las descargas sin publicidad se realizan con las coins

6. Resumen Final — Todo de un Vistazo

6.1. Ideas Clave del Tema

1. **La ética en IA no es diferente** a la ética en cualquier otro campo del conocimiento: los mismos principios morales son aplicables.
2. Es fundamental **alinear los objetivos** del sistema de IA con los objetivos éticos humanos desde la fase de diseño, no como corrección posterior.
3. La **fiabilidad** requiere que la IA sea simultáneamente lícita, ética y robusta durante *todo* su ciclo de vida.
4. La regulación es un proceso **continuo y evolutivo**: las normas deben adaptarse al rápido avance tecnológico.
5. Conocer el marco regulatorio facilita saber qué requisitos debe cumplir un diseño según el **ámbito de aplicación**.

6.2. Comparativa: Principios vs. Requisitos

4 Principios éticos	7 Requisitos clave
Respeto autonomía humana	Acción y supervisión humanas
Prevención del daño	Solidez técnica y seguridad
Equidad	Diversidad, no discriminación y equidad
Explicabilidad	Transparencia
—	Gestión de la privacidad y los datos
—	Bienestar social y ambiental
—	Rendición de cuentas

Cuadro 4: Correspondencia entre los 4 principios éticos y los 7 requisitos clave de la IA fiable.

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.

WUOLAH

Las descargas sin publicidad se realizan con las coins

Importante
Puedo eliminar la publi de este documento con 1 coin
¿Cómo consigo coins? → Plan Turbo: barato
→ Planes pro: más coins

6.3. Puntos Clave para el Examen

★ Checklist del examen

1. Los **3 componentes de la fiabilidad**: lícita + ética + robusta. Los tres son necesarios; ninguno es suficiente por sí solo.
2. Los **4 principios éticos**: autonomía, no daño, equidad, explicabilidad. Hay tensiones entre ellos que deben gestionarse.
3. Los **7 requisitos clave**: supervisión humana, solidez técnica, privacidad, transparencia, no discriminación, bienestar ambiental/social y rendición de cuentas.
4. Los **4 niveles de riesgo** del AI Act: inaceptable (prohibido) → alto (obligaciones estrictas) → limitado (transparencia) → mínimo (libre).
5. **Identificación biométrica** = siempre alto riesgo.
6. **Chatbots** = riesgo limitado (deben informar al usuario de que habla con una máquina).
7. La **Ley de IA** se aprobó en marzo de 2024; la **Oficina Europea de IA** en enero de 2024.

Reservados todos los derechos. No se permite la explotación económica ni la transformación de esta obra. Queda permitida la impresión en su totalidad.